

Resumen ejecutivo

Predicción del precio horario de la energía en Guatemala

El objetivo de este proyecto es construir un modelo de regresión que prediga el precio de oportunidad de la energía (USD/MWh) hora por hora para 2025, usando como historia 2023 y 2024. Los datos de 2025 se apartaron desde el inicio y solo se usaron al final para evaluar.

Datos

Se trabajó con tres archivos anuales de precios horarios del Administrador del Mercado Mayorista (2023, 2024 y 2025), un registro por hora. Al revisarlos encontramos varios errores que hubo que corregir antes de modelar: tres horas mal escritas en 2023, ocho precios que venían guardados como texto o con doble punto decimal, y un dato faltante que se rellenó por interpolación con las horas vecinas. Después de la limpieza cada día quedó con sus 24 horas completas y sin duplicados.

Hallazgos del mercado

El precio típico ronda los 100 USD/MWh, pero la media sube hasta 284 porque hay unos pocos picos de escasez muy altos, con un máximo que supera el millón, concentrados en septiembre y octubre de 2023.

Se ven dos patrones principales. El primero es horario: el precio está más bajo de madrugada y llega a su punto más alto en la tarde/noche. El segundo es estacional, y es el más marcado de todos. El precio sube de marzo a junio, con mayo como el mes más caro, y baja en la segunda mitad del año, siendo diciembre el más barato. Esto tiene que ver con que la matriz de Guatemala depende bastante de las hidroeléctricas, en época seca entran plantas térmicas más caras y el precio sube, y cuando empiezan las lluvias baja. El día de la semana influye poco, lo único que se nota es que el fin de semana es más barato.

Mejor Modelo

Se compararon varios modelos dentro de un Pipeline con ColumnTransformer (un baseline, regresión lineal, polinomial, Ridge, Lasso y combinaciones), prediciendo siempre el logaritmo del precio ($\log_{10}$) para que los picos no dominaran el ajuste. Después se destransforma con $\exp$ para reportar el error en USD/MWh reales.

La optimización con GridSearchCV se quedó con una combinación de variables polinomiales de grado 2 más Ridge con $\alpha = 1000$. En la práctica casi todos los modelos lineales con log dieron resultados muy parecidos (un MAE alrededor de 177 en la validación con 2024), así que la complejidad extra del polinomio no aportó casi nada y un modelo más simple hubiera servido igual.

Las variables que más ayudaron fueron los promedios históricos de precio por mes-hora y por hora, calculados únicamente con datos de entrenamiento, seguidos por las variables de estación. Esto confirma que el precio está muy ligado a patrones que se repiten según el mes y la hora del día.

Resultados sobre 2025

Sobre el año reservado el modelo dio un MAE de 38.4 USD/MWh, una mediana del error de 25.6 y un MAE de 31.7 si se deja afuera el 1% de horas más extremas. Como la mediana del precio en 2025 fue de unos 80 USD/MWh, equivocarse en unos 26 es razonable para un modelo que solo usa calendario e historia del precio.

El R^2 quedó casi en cero, pero eso no quiere decir que el modelo no sirva. Lo que pasa es que el RMSE y el R^2 se calculan con errores al cuadrado, así que los pocos picos de escasez que el modelo no puede predecir terminan pesando muchísimo. De hecho un solo evento, el 15 de enero a las 17h con un precio de más de 54 mil USD/MWh, ya distorsiona esas dos métricas por completo.

Los meses con más error fueron enero y los de época seca (marzo a junio), pero por motivos distintos. En enero el error viene casi todo de ese pico puntual. En la época seca el problema fue que el modelo sobreestimó: como se entrenó con 2023 y 2024, donde esa temporada salió cara, esperaba precios altos que en 2025 no se dieron. En la segunda mitad del año, cuando el nivel se pareció más al de los años anteriores, el error bajó bastante.

Conclusiones del mercado

El modelo es útil como referencia del comportamiento esperado del precio en condiciones normales, pero no para anticipar las crisis de precio, que son las que más le interesarían a alguien del Administrador del Mercado Mayorista. La razón es que solo usamos variables de calendario y de la propia historia del precio, faltarían variables que explican los picos, como la demanda, el nivel de los embalses, la disponibilidad de las plantas y los precios de los combustibles. Sumar ese tipo de información sería el siguiente paso para mejorarlo.